



**Politecnico
di Torino**

Politecnico di Torino

Corso di Laurea
A.A. 2024/2025

Fluorescence Microscopy Challenge

Elaborazione di immagini mediche

Membri del gruppo:

- Maffei Simone (s324097)
- Piccatti Federica (s332069)
- Tarditi Valerio (s322406)
- Traverso Matteo Giovanni (s322816)

1. Introduzione

La "cardiosfera" è un aggregato tridimensionale di cellule progenitrici cardiache che ricrea un microambiente simile a una nicchia di cellule staminali [1].

Negli ultimi anni, le *cardiosphere-derived cells* (CDCs) sono state oggetto di un'intensa ricerca scientifica e sono state progressivamente sviluppate come un promettente candidato terapeutico nel campo della medicina rigenerativa.

Queste cellule rappresentano una potenziale innovazione nel trattamento di patologie cardiovascolari e altre condizioni mediche, grazie alla loro capacità di promuovere la rigenerazione dei tessuti danneggiati e migliorare le funzioni cardiache compromesse [2].

A tale scopo la segmentazione dei nuclei cellulari in immagini di microscopia a fluorescenza è un passaggio fondamentale per l'analisi quantitativa dei campioni biologici. Nel contesto delle cellule staminali cardiache, l'identificazione precisa dei singoli nuclei è essenziale per studiare processi chiave come la proliferazione, la differenziazione e la vitalità cellulare.

Il metodo più accurato e affidabile attualmente disponibile è l'annotazione manuale da parte di esperti, ma questo approccio presenta limitazioni significative, tra cui l'elevato costo in termini di tempo e la variabilità inter- e intra-operatore, che possono influire sulla riproducibilità dei risultati.

L'obiettivo di questo studio è sviluppare un metodo basato sull'uso delle *convolutional neural networks* (CNN) per la segmentazione automatica dei nuclei in immagini di microscopia a fluorescenza. A tal fine, sono state analizzate e confrontate due architetture di reti neurali FCN e PSPNet, valutandone le prestazioni per identificare l'algoritmo più efficace.

2. Materiali e metodi

2.1 Workflow




Figura 1. Workflow completo.

2.2 Dataset




Figure 2-3-4. Immagini di esempio tratte dal dataset; da sinistra verso destra si hanno rispettivamente: esempio di immagine corrotta da rumore “salt and pepper”, immagine non corrotta ed immagine corrotta da rumore gaussiano bianco.

Il dataset fornito è composto da un totale di 90 immagini *gray scale*, con risoluzione 1024 x 1024 pixel. Per ognuna di esse è stata fornita la segmentazione manuale effettuata da un operatore esperto. Le immagini sono state fornite in formato PNG e codificate in uint8.

Per l’allenamento, validazione e testing della rete il Dataset è stato suddiviso in:

- Training set: 80% del Dataset (72 immagini);
- Validation set: 10% del Dataset (9 immagini);
- Test set: 10% del Dataset (9 immagini).

Questa suddivisione è stata preferita a causa della limitata disponibilità di immagini fornite. Di conseguenza, si è scelto di privilegiare la quantità di immagini utilizzate per l’addestramento della rete.

2.3 Metriche per il calcolo delle prestazioni

Al fine di valutare le performance di ogni modello di rete sono state calcolate le seguenti metriche per ciascuna immagine:

1. Il **coefficiente di similarità di Dice** (DSC) tra la maschera automatica e quella manuale, il quale misura la sovrapposizione tra le due maschere e varia tra 0 (nessuna corrispondenza) e 1 (corrispondenza perfetta).

$$DSC(X, Y) = \frac{2 |X \cap Y|}{|X| + |Y|}$$

dove X rappresenta la maschera manuale ed Y la maschera ottenuta tramite la segmentazione automatica.

2. L'**errore assoluto nel conteggio automatico e manuale** del numero di **cellule** presenti, calcolato come la differenza assoluta tra i conteggi automatico e manuale al fine di stimare l'accuratezza della segmentazione proposta

$$Errore_{conteggio} = |N_{cell(manual)} - N_{cell(automatic)}|$$

3. La **Recall**, calcolata come il rapporto tra i veri positivi (TP) e l'effettivo numero di positivi dato dalla somma dei TP con i falsi negativi (FN).

$$Recall = \frac{TP}{TP + FN}$$

2.4 Pre-Processing

Sono state sperimentate varie tecniche di pre-processing, applicate alle immagini prima della suddivisione in patch, per trovare la seguente combinazione in grado di garantire le migliori prestazioni possibili sulle metriche di interesse:

- Filtro mediano con dimensione pari a 3, al fine di ridurre il rumore di tipo *salt and pepper*;
- CLAHE (Contrast Limited Adaptive Histogram Equalization) in modo da uniformare l'istogramma delle luminosità e migliorare il contrasto;
- Filtro gaussiano con dimensione del kernel 5x5 e deviazione standard pari a 2, così da ridurre il contributo del rumore bianco;
- Min-max scaling, per sfruttare al meglio tutta la dinamica delle immagini normalizzando l'intervallo di intensità su tutto il dataset.

Il metodo CLAHE è stato implementato prima dell'applicazione del filtro gaussiano in quanto l'equalizzazione adattiva può causare una diminuzione del rapporto segnale rumore dell'immagine. Questo potrebbe dunque indurre l'algoritmo ad una segmentazione errata di regioni dell'immagine con rumore ad alta frequenza introdotto dal metodo di equalizzazione [3]. È stato inoltre applicato solamente per la rete FCN poiché per la rete PSPNet si riscontrava un deciso peggioramento delle metriche di valutazione.




Figura 5. Schema rappresentativo dell'applicazione delle operazioni di pre-processing. Si possono notare i miglioramenti ottenuti per l'immagine sulla destra rispetto a quella di partenza sulla sinistra.

2.5 Rete Neurale

Per effettuare la segmentazione sono state selezionate due architetture di rete: Fully Convolutional Network (FCN) e Pyramid Scene Parsing Network (PSPNet), implementate tramite il framework MMSegmentation.

La scelta delle reti è stata condizionata da limiti computazionali e di tempo. In particolare, la rete FCN è stata implementata per la sua semplicità e velocità di addestramento, la rete PSPNet invece è stata allenata principalmente per la sua capacità di riconoscere piccoli particolari a fronte però di un maggiore tempo di allenamento.

Le due reti sono state configurate per elaborare immagini di dimensioni 128 x 128 pixel al fine di segmentare due classi: sfondo e nucleo. Sono state così allenate entrambe le tipologie di rete usando le seguenti loss function: Dice Loss, CrossEntropy Loss e Sigmoidal Focal Loss.

Nella Tabella 1 e 2 sono riportati i relativi risultati intermedi per le metriche di interesse.

È inoltre presente un tentativo aggiuntivo effettuato utilizzando la CrossEntropy Loss ed un sistema di *data augmentation*, per migliorare la capacità di generalizzazione del modello e prevenire l'*overfitting*^[4], aumentando la numerosità del dataset.

Nello specifico, le operazioni di *data augmentation* utilizzate includono:

- *Random resize*: modifica casuale delle dimensioni dell'immagine mantenendo inalterato il rapporto tra le due;
- *Random rotation*: rotazione dell'immagine di 45 gradi con impostata una probabilità di occorrenza pari al 50%;
- *Photometric distortion*: modifiche casuali alla luminosità, contrasto e saturazione per simulare diverse condizioni di illuminazione;
- *Random flip*: riflessione orizzontale casuale dell'immagine con impostata una probabilità di occorrenza pari al 50%;
- *Random crop*: ritaglio casuale di una porzione dell'immagine per introdurre varietà nel campo visivo della rete
- Dopo aver allenato le reti ed aver così selezionato la migliore per ogni tipologia, sono state effettuate ulteriori prove facendo variare il valore di Batch Size: 4, 9, 18, 36, 72.

Inoltre, il numero di epoche di allenamento è stato impostato a 20. Tale valore è stato scelto in quanto andando ad aumentarlo non è stato osservato un miglioramento apprezzabile delle prestazioni dei modelli durante i vari checkpoint di training. Questo ha garantito oltretutto una riduzione del rischio di andare incontro ad *overfitting*.

Le immagini utilizzate per l'addestramento della rete sono state pre-elaborate per migliorare la qualità dei dati grezzi su cui la rete è stata allenata. In particolare, sono stati applicati filtri mediani e gaussiani per la rimozione del rumore.

2.6 Inference

Le immagini da analizzare vengono suddivise in patch di dimensioni 128x128 pixel con un valore di *overlap* pari a 16 pixel, successivamente vengono fornite in input alla rete.

Per ottenere l'immagine segmentata, durante la fase di ricostruzione, viene eseguito un or logico dei pixel sovrapposti delle maschere binarie, in modo tale da garantire consistenza nei nuclei segmentati tra due patch differenti contigue.

2.7 Post-processing

Analogamente a quanto svolto nella fase di pre-processing, anche in tal caso è risultata necessaria la sperimentazione di differenti combinazioni e di tecniche di post-processing in modo tale da migliorare la segmentazione eseguita da parte della rete neurale. Si riportano di seguito le procedure implementate:

- Rimozione di oggetti con dimensioni minori ad una determinata soglia di area (pari a 100);
- Riempimento di buchi con dimensioni minori ad una determinata soglia di area (pari a 100);
- Dilatazione con elemento strutturale disco di raggio unitario, al fine di far crescere i nuclei segmentati più piccoli;
- Separazione di eventuali nuclei sovrapposti mediante l'utilizzo di una *marker controlled watershed transform*, realizzata tramite una distance transform con elemento strutturale di forma ellittica, così da essere più simile alla effettiva morfologia dei nuclei;
- Opening (erosione seguita da dilatazione) con elemento strutturale disco di raggio pari a 3, per migliorare la separazione precedentemente eseguita dalla *watershed transform*.




Figura 6. Schema rappresentativo dell'applicazione delle operazioni di post-processing. Si può notare l'eliminazione di oggetti di piccole dimensioni, la separazione di alcuni nuclei oltre al riempimento di alcune zone vuote al centro degli stessi.

2.7.1 Contouring

È inoltre stato implementato un algoritmo di contouring che permette di migliorare la visualizzazione dei bordi dei nuclei segmentati in modo automatico sull'immagine originale. Per eseguire questa operazione è stata utilizzata la libreria *cv2* di Python che identifica i contorni degli oggetti nelle immagini binarie andando a identificare i pixel in cui avviene un cambio di luminosità. Nel caso delle maschere ottenute, questo algoritmo risulta essere molto più efficace di un modello deformabile parametrico (anche detto *snake*) perché quest'ultimo aumenterebbe i tempi di post-processing, essendo basato su un algoritmo iterativo.

3. Risultati

È stata osservata una differenza quantitativa nei risultati ottenuti, evidenziata in particolare dalla variazione dell'errore medio nel calcolo dei nuclei. La scelta della rete “vincitrice” è stata effettuata in base alle performance registrate, dando priorità al valore del coefficiente di Dice e all'errore sui nuclei. La recall è stata considerata solo nel caso in cui le altre due metriche non fossero sufficienti per prendere una decisione chiara.

Le Tabelle 1 e 2 mostrano i risultati ottenuti sul Validation Set, rispettivamente per la rete FCN e PSPNet. In particolare, riportano le metriche per le relative Loss Function valutate sul validation set dopo ogni fase di training.

<i>Rete FCN_128x128 - Validation Set – Rimozione rumore</i>			
Loss Function	DSC $\pm$ std	Recall $\pm$ std	Errore sui nuclei $\pm$ std
CrossEntropy	0.801 $\pm$ 0.037	0.821 $\pm$ 0.039	11 $\pm$ 8
Dice	0.803 $\pm$ 0.033	0.810 $\pm$ 0.036	10 $\pm$ 7
Sigmoidal Focal	0.797 $\pm$ 0.032	0.805 $\pm$ 0.035	8 $\pm$ 7
CrossEntropy (Data Augmentation)	0.801 $\pm$ 0.032	0.801 $\pm$ 0.040	7 $\pm$ 7

Tabella 1. Valori medi su tutte le immagini delle metriche selezionate in funzione delle differenti funzioni di perdita per la FCN.

<i>Rete PSPNet_128x128 - Validation – Rimozione rumore</i>			
Loss Function	DSC $\pm$ std	Recall $\pm$ std	Errore sui nuclei $\pm$ std
CrossEntropy	0.802 $\pm$ 0.038	0.839 $\pm$ 0.035	9 $\pm$ 8
Dice	0.799 $\pm$ 0.038	0.795 $\pm$ 0.061	13 $\pm$ 8
Sigmoidal Focal	0.784 $\pm$ 0.046	0.745 $\pm$ 0.071	13 $\pm$ 7
CrossEntropy (Data Augmentation)	0.800 $\pm$ 0.036	0.835 $\pm$ 0.037	9 $\pm$ 7

Tabella 2. Valori medi su tutte le immagini delle metriche selezionate in funzione delle differenti funzioni di perdita per la PSPnet.

La riga evidenziata in giallo indica la configurazione selezionata in fase di inference per le successive analisi, in quanto garantiva ottime prestazioni a parità di iperparametri selezionati (numero epoche = 20, Batch Size = 72) ed inoltre, avendo implementato una *data augmentation*, si è supposto che garantisse un migliore adattamento della rete ad immagini con caratteristiche diverse da quelle presenti nel dataset.

Le metriche riportate nelle tabelle sono calcolate come la media delle metriche di ciascuna immagine.

Nelle Tabelle 3 e 4 sono riportati i risultati finali con l'applicazione del pre-processing e del post-processing completi, come precedentemente illustrato, al variare del Batch Size.

Rete FCN_128x128 - Validation Set – Post-processing			
Batch size	DSC $\pm$ std	Recall $\pm$ std	Errore sui nuclei $\pm$ std
4	0.815 $\pm$ 0.036	0.839 $\pm$ 0.049	5 $\pm$ 8
9	0.801 $\pm$ 0.040	0.869 $\pm$ 0.039	2 $\pm$ 9
18	0.791 $\pm$ 0.040	0.880 $\pm$ 0.038	1 $\pm$ 10
36	0.793 $\pm$ 0.039	0.865 $\pm$ 0.039	1 $\pm$ 10
72	0.788 $\pm$ 0.040	0.853 $\pm$ 0.041	2 $\pm$ 8

Tabella 3. Valori medi su tutte le immagini delle metriche selezionate in funzione delle differenti dimensioni del batch size per la rete FCN.

Rete PSPNet_128x128 - Validation Set – Post-processing			
Batch size	DSC $\pm$ std	Recall $\pm$ std	Errore sui nuclei $\pm$ std
4	0.808 $\pm$ 0.034	0.845 $\pm$ 0.037	5 $\pm$ 9
9	0.786 $\pm$ 0.044	0.870 $\pm$ 0.031	3 $\pm$ 10
18	0.802 $\pm$ 0.039	0.850 $\pm$ 0.045	4 $\pm$ 9
36	0.791 $\pm$ 0.038	0.869 $\pm$ 0.036	3 $\pm$ 9
72	0.785 $\pm$ 0.056	0.856 $\pm$ 0.054	5 $\pm$ 12

Tabella 4. Valori medi su tutte le immagini delle metriche selezionate in funzione delle differenti dimensioni del batch size per la rete PSPnet.

Nella Tabella 5 viene illustrato l'andamento delle performance con l'aggiunta delle varie tecniche di pre-processing e post-processing per la rete selezionata.

Rete FCN_128x128 (Batch Size = 4) - Validation Set – Studio Di Ablazione			
Tecnica	DSC $\pm$ std	Recall $\pm$ std	Errore sui nuclei $\pm$ std
No pre-processing	0.797 $\pm$ 0.038	0.752 $\pm$ 0.060	3 $\pm$ 5
Filtraggio Gaussiano e Mediano	0.810 $\pm$ 0.039	0.782 $\pm$ 0.059	8 $\pm$ 5
CLAHE	0.817 $\pm$ 0.032	0.832 $\pm$ 0.044	5 $\pm$ 6
Min-Max Scaling	0.817 $\pm$ 0.031	0.832 $\pm$ 0.041	5 $\pm$ 6
Rimozione oggetti + Riempimento buchi	0.819 $\pm$ 0.033	0.803 $\pm$ 0.048	16 $\pm$ 10
Dilatazione + Watershed	0.815 $\pm$ 0.036	0.839 $\pm$ 0.049	6 $\pm$ 8

Tabella 5. Studio di Ablazione contenente i valori medi delle metriche in funzione delle tecniche di elaborazione implementate.

Nella Tabella 6 vengono riportate per un confronto le metriche ottenute per Validation Set e Test Set applicati alla fase di inference con l'aggiunta di pre-processing e post-processing.

DSC $\pm$ std	Recall $\pm$ std	Errore sui nuclei $\pm$ std
Test Set		
0.810 $\pm$ 0.035	0.833 $\pm$ 0.067	7 $\pm$ 6
Validation Set		
0.815 $\pm$ 0.036	0.839 $\pm$ 0.049	6 $\pm$ 8

Tabella 6. Confronto tra le metriche finali ottenute tramite l'applicazione della rete selezionata sul Test Set e sul Validation Set.

È possibile osservare l'effetto dei metodi illustrati nello studio di ablazione in Figura 6.




Figura 7. Visualizzazione del miglioramento delle prestazioni di segmentazione della rete neurale. In ordine da in alto a sinistra verso in basso a sinistra si può osservare: A) Applicazione diretta senza pre-processing; B) Applicazione della rete a seguito di un filtraggio gaussiano e mediano delle immagini; C) Applicazione della rete a seguito dell'applicazione di filtri e CLAHE sulle immagini; D) Applicazione della rete con l'aggiunta di una normalizzazione; E) Applicazione della rete con l'aggiunta di rimozione oggetti e riempimento buchi; F) Pipeline completa con implementata la separazione tra nuclei mediante Watershed e opening.

4. Analisi e criticità

Nonostante i risultati possano essere considerati soddisfacenti per lo scopo clinico, sono state riscontrate alcune problematiche di cui un esempio viene riportato in Figura 8.




Figura 8. Confronto tra maschera manuale (sinistra) e maschera automatica (destra).

In questo caso particolare, all'interno del riquadro rosso si può osservare come, nonostante i nuclei siano stati contati in maniera corretta, le loro dimensioni risultino inferiori a quelle presenti nella maschera manuale così come la morfologia si presenta leggermente alterata. È inoltre evidente che la rete neurale classifichi erroneamente come nuclei zone particolarmente soggette a rumore, come mostrato nel riquadro blu, probabilmente a causa di un'intensità comparabile tra oggetto e sfondo. In ultimo, nel riquadro verde si nota un'altra possibile limitazione legata all'algoritmo di post-processing che non sempre è in grado di separare correttamente due nuclei fusi tra loro.

In alternativa alla pipeline che prevede l'utilizzo della rete neurale, è stato sviluppato e testato in un primo momento anche l'algoritmo CARE, illustrato nell'articolo [1]. Tuttavia, questo approccio è stato abbandonato poiché soggetto alle problematiche dei metodi di thresholding, particolarmente efficaci su immagini con istogrammi delle luminosità bimodali ma molto sensibili ad artefatti dell'immagine (rumore, saturazione, etc.). In Figura 9 viene riportata la maschera analoga a quella mostrata nella figura precedente; si può facilmente notare le difficoltà riscontrate nell'isolare i nuclei rispetto al rumore.




Figura 9. Maschera ottenuta con algoritmo CARE, completa di pre e post processing.

4.1 Sviluppi Futuri

Durante la fase di selezione delle reti, sono state effettuate alcune prove di training con l'obiettivo di testare l'efficacia di una rete neurale U-net, in particolare nella variante *Deeplabv3*. Tuttavia, l'addestramento della rete non è stato completato con successo a causa dei lunghi tempi di computazione richiesti. Nonostante ciò, l'approccio sembra promettente e potrebbe costituire una modifica interessante e vantaggiosa da apportare alla pipeline proposta, poiché, come riportato nell'articolo [5], tale architettura ha dimostrato un'ottima capacità di segmentazione, anche in contesti complessi.

Inoltre, un altro aspetto che potrebbe migliorare la performance complessiva del sistema riguarda il post-processing, in particolare per la separazione dei nuclei. La *marker controlled watershed transform*, sebbene utile, ha mostrato limitazioni nella capacità di effettuare distinzioni accurate tra nuclei adiacenti, specialmente quando questi sono molto vicini o parzialmente fusi. In tale contesto, potrebbe risultare particolarmente efficace l'implementazione di un metodo di post-processing che prenda in considerazione la morfologia dei nuclei. In particolare, il metodo DEFA (*Decreasing Ellipse Fitting Algorithm*) illustrato nell'articolo [6] si è rivelato interessante, in quanto si basa su un approccio che utilizza il calcolo dello skeleton dei nuclei e il fitting di ellissi per identificare e separare correttamente gli oggetti fusi. Questo algoritmo potrebbe quindi migliorare significativamente la separazione dei nuclei, riducendo gli errori derivanti dalla semplice applicazione della trasformata watershed, e aumentando l'affidabilità del sistema di segmentazione.

Bibliografia

- [1] Salvi, M., Morbiducci, U., Amadeo, F. *et al.* Automated Segmentation of Fluorescence Microscopy Images for 3D Cell Detection in human-derived Cardiospheres. *Sci Rep* **9**, 6644 (2019). <https://doi.org/10.1038/s41598-019-43137-2>
- [2] Marbán, E., Liao, K. On the cellular origin of cardiosphere-derived cells (CDCs). *Basic Res Cardiol* **117**, 12 (2022). <https://doi.org/10.1007/s00395-022-00914-x>
- [3] Long, F. Microscopy cell nuclei segmentation with enhanced U-Net. *BMC Bioinformatics* **21**, 8 (2020). <https://doi.org/10.1186/s12859-019-3332-1>
- [4] Gudhe NR, Kosma VM, Behravan H, Mannermaa A. Nuclei instance segmentation from histopathology images using Bayesian dropout based deep learning. *BMC Med Imaging*. 2023 Oct 19;23(1):162. <https://doi.org/10.1186/s12880-023-01121-3>
- [5] Memon MM, Hashmani MA, Junejo AZ, Rizvi SS, Raza K. Unified DeepLabV3+ for Semi-Dark Image Semantic Segmentation. *Sensors (Basel)*. 2022 Jul 15;22(14):5312. doi: 10.3390/s22145312. PMID: 35890992; PMCID: PMC9324997.
- [6] Fang Y, Zhong B. Cell segmentation in fluorescence microscopy images based on multi-scale histogram thresholding. *Math Biosci Eng*. 2023 Aug 14;20(9):16259-16278. doi: 10.3934/mbe.2023726. PMID: 37920012.